

Dane są zmienne X_1, X_2, X_3, \dots oraz Y . Zakładamy zależność:

$$Y = a_0 + a_1X_1 + a_2X_2 + a_3X_3 + \dots$$

gdzie parametry a_0, a_1, a_2, \dots należy oszacować na podstawie danych. W przypadku gdy mamy tylko jedną zmienną X , zależność ta przyjmuje formę:

$$Y = aX + b.$$


Zauważmy, że w ogólnym przypadku X_1, X_2, \dots, Y przyjmują wartości rzeczywiste.


- W przypadku gdy Y może przyjmować tylko dwie wartości - przykładowo 0 i 1 stosowanie regresji liniowej jest nieuzasadnione.
- W tym przypadku definiujemy $p = P(Y = 1)$, $q = P(Y = 0)$.
- Oczywiście $p + q = 1$, zatem $q = 1 - p$. Celem regresji logistycznej jest oszacowanie p .
- Zakładamy następującą jego postać:

$$p = \frac{1}{1 + e^{-(a_0 + a_1 X_1 + a_2 X_2 + a_3 X_3 + \dots)}}$$

- Jeżeli $p > 0.5$ to obserwacje klasyfikujemy do grupy 1, w przeciwnym przypadku do grupy 0.

SVM






Przykład

X1	X2	Y
0	-1	0
0.4	-2	0
-0.5	-2	0
-0.4	-1	0
4	-2	0
-2	0	0
2.5	2	0
0	2	0
0.5	3	1
1	3	1
3	-1	1
1	-2	1
2	3	1
2	2	1
2	-1	1

- Rozwiązanie z SVM:



- Rozwiązanie z regresją logistyczną:

$$p = \frac{1}{1 + e^{-(-0.9011 + 0.5861x_1 + 0.4331x_2)}}$$

Przykładowo dla pierwszej obserwacji (0,-1) jest

$p = \frac{1}{1 + e^{-(-0.9011 + 0.5861 \cdot 0 + 0.4331 \cdot (-1))}} = 0.21 < 0.5$, zatem zaliczamy ją do klasy 0.